#### 소프트웨어시스템실습

5강: 데이터 시각화 (그래프)




# 산점도(scatter plot)



- plot(x, y)
- 예)
- > install.packages("mlbench")
- > library(mlbench)
- > data(Ozone) <
- > plot(Ozone\$V8, Ozone\$V9)

Mlbench패키지에 저장된 Ozone데이터 loading

각각 캘리포니아 Sandburg와 El Monte에서 매일 측정한 온도



Sandburg(V8)와 El Monte(V9)지역의 온도




### 그래픽 옵션



▶ 축 이름(xlab, ylab)

```
> plot(Ozone$V8, Ozone$V9, xlab="Sandburg Temperature",
+ ylab="El Monte Temperature")
```






### 그래픽 옵션



▶ 그래프 제목(main)

```
> plot(Ozone$V8, Ozone$V9, xlab="Sandburg Temperature",
+ ylab="El Monte Temperature", main="Ozone")
```

#### Ozone








#### ▶ 점의 종류(pch)

- ▶ 숫자를 지정하면 미리 지정된 심볼 (구글에서 'r pch symbols' 로 검색)
- ▶ 문자(예를들어 '+')를 지정하면 그 문자를 사용

```
> plot(Ozone$V8, Ozone$V9, xlab="Sandburg Temperature",
+ ylab="El Monte Temperature", main="Ozone", pch=20)
> plot(Ozone$V8, Ozone$V9, xlab="Sandburg Temperature",
+ ylab="El Monte Temperature", main="Ozone", pch="+")
```








▶ 점의 크기(cex)

```
> plot(Ozone$V8, Ozone$V9, xlab="Sandburg Temperature",
+ ylab="El Monte Temperature", main="Ozone", cex=.1)
```

#### Ozone








- ▶ 색상(col)
  - ▶ col="#FF0000" 또는 col="red
  - ▶ 목록은 colors()로 확인

```
> plot(Ozone$V8, Ozone$V9, xlab="Sandburg Temperature",
+ ylab="El Monte Temperature", main="Ozone", col="#FF0000")
```

#### Ozone







▶ 좌표축 값의 범위(xlim, ylim)

```
> plot(Ozone$V8, Ozone$V9, xlab="Sandburg Temperature",
       ylab="El Monte Temperature", main="Ozone")
                                                                          Ozone
> max(Ozone$V8)
                                                        El Monte Temperature
                                                           8
[1] NA
                                                           8
> max(Ozone$V8, na.rm=TRUE)
[1] 93
                                                           20
> max(Ozone$V9, na.rm=TRUE)
[1] 82.58
                                                                    20
                                                                         40
                                                                              60
                                                                                   80
                                                                                        100
> plot(Ozone$V8, Ozone$V9, xlab="Sandburg Temperat
                                                                     Sandburg Temperature
       ylab="El Monte Temperature", main="Ozone",
       xlim=c(0, 100), ylim=c(0, 90))
```

### 그래프 옵션



#### type

▶ 예) cars 데이터: 속도에서 브레이크를 잡았을 때 제동거리를 측정


```
> data(cars)
> str(cars)
'data.frame': 50 obs. of 2 variables:
 $ speed: num
   dist : num
                          16
                             10 18 26 34 17 ...
> head(cars)
  speed dist
                                                 100
1
          10
          4
                                                 8
          22
                                                         0000000
          16
                                                 20
6
          10
> plot(cars)
                                                              10
                                                                     15
                                                                           20
                                                                                  25
                                                       5
                                                                  speed
```






> plot(cars, type="l")

> plot(cars, type="o", cex=0.5)





### 그래프 옵션


```
000
```

```
> tapply(cars$dist, cars$speed, mean)
                                    10
                                                  11
                                                           12
6.00000 13.00000 16.00000 10.00000 26.00000 22.50000 21.50000
                       15
                                16
     13
              14
                                         17
                                                  18
35.00000 50.50000 33.33333 36.00000 40.66667 64.50000 50.00000
                       23
     20
              22
                                24
                                         25
50.40000 66.00000 54.00000 93.75000 85.00000
> plot(tapply(cars$dist, cars$speed, mean), type="o", cex=0.5,
      xlab="speed", ylab="dist")
                                               8
                                               9
                                               4
                                               2
                                                                 10
                                                                         15
                                                          5
                                                               speed
```




000

- ▶ 선유형(Ity)
- ▶ 예) plot(card, type="l", lty="dashed")



### ㅇㅇㅇ그래프 옵션(그래프의 배열(mfrow)) ㅇㅇㅇ

- 한 창에 여러 개의 그래프를 나열
  - ▶ par(mfrow = c(nr, nc)) #행과 열의 개수 지정



Par를 호출하면 이전 설정을 반환함. 이를 기억했다가 나중에 돌려놈



### 그래픽 옵션



- ▶ 지터(jitter) 중복 표현 방지를 위해 약간의 노이즈 추가
  - ▶ 예) Ozone데이터의 V6와 V7은 각각 LAX에서의 풍속과 습도

```
> head(Ozone)
                V5 V6 V7 V8
                                     V10 V11
                                                V12 V13
                       20 NA
                                NA 5000 -15 30.56 200
              5480
            3 5660
                     6 NA 38
                                NΑ
                                                 NA 300
                                NA 2693 -25 47.66 250
            3 5710
                       28 40
            5 5700
                       37 45
                                 NA
                                     590 -24 55.04 100
                       51 54 45.32 1450
            5 5760
                     3
            6 5720
                     4 69 35 49.64 1568
                                          15 53.78
                                                     60
```

많은 중복



## 그래픽 옵션


```
000
```

```
> plot(Ozone$V6, Ozone$V7, xlab="Windspeed", ylab="Humidity",

+ main="Ozone", pch=20, cex=.5)
> plot(jitter(Ozone$V6), jitter(Ozone$V7),

+ xlab="Windspeed", ylab="Humidity", main="Ozone",

+ pch=20, cex=.5)
```








- ▶ 점(points)
  - ▶ point() : 이미 생성된 plot에 점을 추가

```
> plot(iris$Sepal.Width, iris$Sepal.Length, cex=.5, pch=20,
+ xlab="width", ylab="length", main="iris")
> points(iris$Petal.Width, iris$Petal.Length, cex=.5,
+ pch="+", col="#FF0000")
```

#### iris








▶ 빈 그래프 먼저 그리고 나중에 추가하기 (type = n)

```
> with(iris, {
+ plot(NULL, xlim=c(0, 5), ylim=c(0, 10),
+ xlab="width", ylab="length", main="iris", type="n")
+ points(Sepal.Width, Sepal.Length, cex=.5, pch=20)
+ points(Petal.Width, Petal.Length, cex=.5, pch="+", col="#FF0000")
+ })
```

#### iris




xlim과 ylim을 생략하면 초기 빈 그래프가 만들어지지 않음





- ▶ 선(lines)
  - 예) [0, 2π]까지 sin 그래프

```
> x <- seq(0, 2*pi, 0.1)
> y <- sin(x)
> plot(x, y, cex=.5, col="red")
> lines(x, y)
```






> lowess(cars)



#### ▶ 회귀 분석(추세선 구하기)

- > plot(cars)
  > lines(lowess(cars))
- \$y
  [1] 4.965459 4.965459 13.124495 13.124495 15.858633 18.579691 21.280
  - 9 30.027276 30.027276 30.027276 30.027276 32.962506 32.9625
  - 6 32.962506 36.757728 36.757728 36.757728 40.435075 40.4350

3 21.280313 24.129277 24.129277 27.119549 27.119549 27.1195



speed

회귀분석(x에 대항하는 y값 추정) plot(lowess(cars)) 실행해볼 것


### 기본 그래프



#### ▶ 직선(abline)

- ▶ y = a + bx, y = h, x = v 형태의 직성 그리기
- ▶ 예) cars 데이터에서 dist = -5 + 3.5 × speed와 같은 직선 그리기

```
> plot(cars, xlim=c(0, 25))
> abline(a=-5, b=3.5, col="red")
```








#### ▶ 그래프에 speed와 dist의 평균 직선 그리기

```
> plot(cars, xlim=c(0, 25))
> abline(a=-5, b=3.5, col="red")
> abline(h=mean(cars$dist), lty=2, col="blue")
> abline(v=mean(cars$speed), lty=2, col="green")
```




a, b, h, v는 고정



#### 000

- ▶ 곡선(curve)
  - curve(expr, from, to)

```
> curve(sin, 0, 2*pi)
```



# 범례(legend)




```
> plot(iris$Sepal.Width, iris$Sepal.Length, cex=.5, pch=20,
+ xlab="width", ylab="length")
> points(iris$Petal.Width, iris$Petal.Length, cex=.5,
+ pch="+", col="#FF0000")
> legend("topright", legend=c("Sepal", "Petal"),
+ pch=c(20, 43), cex=.8, col=c("black", "red"), bg="gray")
                                                                               Sepal
                                                                               Petal
벡터형태이므로
자료형을 통일
                                          6.5
                                    length
          x, y좌표를 지정해도 됨
                                          5
                                          5
                                          4.5
                                               2.0
                                                      2.5
                                                             3.0
                                                                     3.5
                                                                            4.0
                                                               width
```



# 상자 그림(boxplot)



▶ 제1사분위수, 중앙값, 제3사분위수를 보여준다.





# 상자 그림(boxplot)




```
> boxstats <- boxplot(iris$Sepal.Width)
> boxstats
$stats
     [,1]
[1,]
      2.2
[2,]
      2.8
                                                      신뢰구간
                       $conf
[3,] 3.0
                                [,1]
[4,] 3.3
                       [1,] 2.935497
[5,]
      4.0
                       [2,] 3.064503
$n
                       $out
[1] 150
                       [1] 4.4 4.1 4.2 2.0
                       $group
                       [1] 1 1 1 1
                       $names
                       [1] "1"
```



## 상자 그림(boxplot)



▶ iris의 setosa종과 versicolor종의 Sepal.Width에 대한 상자 그림을 그린 뒤 이 두 종의 중앙 값이 다른지 비교






## 히스토그램(hist)



```
hist(
x, #벡터데이터
breaks="Struge", #막대너비.기본값은 Struge로 n개일때 [log2(n)+1]
#또는데이터를 나눌 구분 값이 저장된 벡터 또는 함수
freq=NULL, #기본은 빈도수, FALSE면 확률밀도
)
```

#### Histogram of iris\$Sepal.Width

> hist(iris\$Sepal.Width)



iris\$Sepal.Width




## 히스토그램(hist)



> hist(iris\$Sepal.Width, freq=FALSE)


넓이가1인 확률밀도

#### Histogram of iris\$Sepal.Width



> hist(iris\$Sepal.Width, breaks=c(1, 2, 3, 4, 5))

#### Histogram of iris\$Sepal.Width



## 히스토그램(hist)



```
> x <- hist(iris$Sepal.Width, freq=FALSE)
> x
$breaks
 [1] 2.0 2.2 2.4 2.6 2.8 3.0 3.2 3.4 3.6 3.8 4.0 4.2 4.4
$counts
 Γ11
     4 7 13 23 36 24 18 10
$intensities
 [1] 0.13333333 0.23333333 0.43333333 0.76666667 1.20000000
 [6] 0.80000000 0.60000000 0.33333333 0.30000000 0.10000000
[11] 0.06666667 0.03333333
$density
 [1] 0.13333333 0.23333333 0.43333333 0.76666667 1.20000000
 [6] 0.80000000 0.60000000 0.33333333 0.30000000 0.10000000
[11] 0.06666667 0.03333333
```




# 밀도 그림(density)




- ▶ 막대의 너비를 가정하지 않음
- 모든 점에서 밀도를 추정: 커널밀도추정방식

> plot(density(iris\$Sepal.Width))



#### 밀도그림과 히스토그램을 동시 표출

- > hist(iris\$Sepal.Width, freq=FALSE)
- > lines(density(iris\$Sepal.Width))






# 막대 그래프(barplot)



#### **)** 예)

- > x < c(2,5,8,5,7,10,11,3,4,7,12,15)
- > barplot(x)






# 막대 그래프(barplot)




```
> barplot(tapply(iris$Sepal.Width, iris$Species, mean))
```



## 파이(pie) 그래프


```
000
```

```
> slices <- c(10, 12,4, 16, 8)
> pie(slices)
```



```
> slices <- c(10, 12,4, 16, 8)
> lbls <- c("US", "UK", "Australia", "Germany", "France")
> pie(slices, labels = lbls, main="Pie Chart of Countries")
```

#### **Pie Chart of Countries**



## ㅇㅇㅇ 모자이크 플롯(mosaicplot)

000

- ▶ 범주형 다변량 데이터를 표현(table형태의 분할표를 표현)
- ▶ 분할표
  - 명목형, 순서형 데이터의 돗수 표현
  - ) 예)

	테스트-양성	테스트-음성
실제 -양성	92	5 (위음성)
실제- 음성	7(위양성)	42

▶ 예) Titanic data

```
> str(Titanic)
table [1:4, 1:2, 1:2, 1:2] 0 0 35 0 0 0 17 0 118 154 ...
- attr(*, "dimnames")=List of 4
    ..$ Class : chr [1:4] "1st" "2nd" "3rd" "Crew"
    ..$ Sex : chr [1:2] "Male" "Female"
    ..$ Age : chr [1:2] "Child" "Adult"
    ..$ Survived: chr [1:2] "No" "Yes"
```


```
> Titanic
, , Age = Child, Survived = No
    Sex
Class Male Female
 1st
      0
 2nd
     0
     35 17
 3rd
 Crew
      0
          0
, , Age = Adult, Survived = No
    Sex
Class Male Female
     118
 1st
 2nd
     154 13
     387
 3rd
          89
            3
 Crew 670
, , Age = Child, Survived = Yes
```

# 모자이크 플롯(mosaicplot)



> mosaicplot( $\sim$  Class + Survived, data=Titanic, color=TRUE)

#### **Titanic**






#### ggplot2 패키지



Elegant Graphics Tool for Data Analysis



▶ ggplot2 도움말 사이트: http://docs.ggplot2.org/current/



library(ggplot2)

install.packages("ggplot2")

qplot(diamonds\$carat, diamonds\$price) qplot(carat, price, data = diamonds)

#### qplot() 함수

```
qplot(carat, price, data = diamonds, geom="point" , colour=clarity) # --
                                                                                                               clarity

    WS2

    VVS1
```

carat

```
> str(diamonds)
Classes 'tbl_df', 'tbl' and 'data.frame':
                                                53940 obs. of 10 variables:
 $ carat : num 0.23 0.21 0.23 0.29 0.31 0.24 0.24 0.26 0.22 0.23 ...
          : Ord.factor w/ 5 levels "Fair"<"Good"<...: 5 4 2 4 2 3 3 3 1 3 ...
 $ color : ord.factor w/ 7 levels "D"<"E"<"F"<"G"<...: 2 2 2 6 7 7 6 5 2 5 ...</pre>
 $ clarity: Ord.factor w/ 8 levels "I1"<"SI2"<"SI1"<...: 2 3 5 4 2 6 7 3 4 5 ...</pre>
 $ table
                55 61 65 58 58 57 57 55 61 61 ...
 $ price : int 326 326 327 334 335 336 336 337 337 338 ...
          : num 3.95 3.89 4.05 4.2 4.34 3.94 3.95 4.07 3.87 4 ...
 $ x
 $ y
          : num 3.98 3.84 4.07 4.23 4.35 3.96 3.98 4.11 3.78 4.05 ...
          : num 2.43 2.31 2.31 2.63 2.75 2.48 2.47 2.53 2.49 2.39 ...
```

Clarity가 좋을 수록, Carat에 대한 price가 크게 반응함

# ㅇㅇㅇ qplot() 함수

```
15000-
pplot(carat, data = diamonds,geom="histogram")
qplot(carat, data = diamonds,geom="histogram", binwidth=0.2, colour=clarity)
                                                                                                 clarity
                                                             5000-
                                                                               carat
```

■ Plot Zoom

\_ D X

#### OOO ggplot() 함수




#### aesthetic mapping

x축에 length 컬럼, y축에 width 컬럼을 매핑

▶ 미적매핑 이후에 필요한 레이어 계속 추가

ggplot(data=diamonds, aes(x=carat, y=price)) + geom\_point(aes(colour=clarity)) + geom\_smooth()

- ▶ 처음에 aes 매핑한 후 geom\_point() 함수만 그 매핑정 보를 승계하여 coloring
- ▶ geom\_smooth() 함수는 초기 aes 매핑한 것에 대하여 회귀선을 그림




#### OOO ggplot() 함수


▶ 앞의 예와 비교

ggplot(data=diamonds, aes(x=carat, y=price, colour=clarity)) +
 geom\_point() + geom\_smooth()

▶ 초기에 aes 매핑할 때 colour 옵션까지 넣었으므로, geom\_smooth()함수는 각 colour값에 대한 8가지 회귀선을 그리게 됨




# OOO ggplot() 함수: geom\_smooth



# ggplot() 함수: geom\_bar


```
ggplot(data=diamonds, aes(x=price)) + geom_bar()
ggplot(data=diamonds, aes(x=price)) + geom_bar(aes(y=..count..))
ggplot(data=diamonds, aes(x=price)) + geom_bar(aes(y=..density..))
ggplot(data=diamonds, aes(x=price)) + geom_bar(aes(y=..ncount..))
ggplot(data=diamonds, aes(x=price)) + geom_bar(aes(y=..ndensity..))
ggplot(data=diamonds, aes(x=price)) + geom_bar(aes(y=..density..)) + ylab("밀도")
```



10000


5000


- count: 각 빈(bin)에 해당하는 관측값의 개수
- density: 각 빈(bin)의 밀도 (전체의 합이 1)
- ncount: count와 같으나 [0,1]로 스케일링
- ndensity: density와 같으나 [0,1]로 스케일링



#### OOO ggplot() 함수: geom\_histogram OOO


```
ggplot(diamonds, aes(carat)) + geom_histogram(binwidth = 1)
ggplot(diamonds, aes(carat)) + geom_histogram(aes(fill=cut), binwidth = 1)
```





# OOO ggplot() 함수: geom\_histogram OOO

```
ggplot(diamonds, aes(carat)) +
geom_histogram(aes(fill=cut), binwidth = 1, position="dodge")
```



# OO ggplot() 함수: geom\_boxplot

000

```
4.5
p <- ggplot(iris, aes(Species, Sepal.Width))</pre>
  + geom_boxplot()
                                                                    Sepal.Width 3.0-
                                                                      2.5-
                                                                      2.0 -
                                                                              setosa
                                                                                          versicolor
                                                                                                       virginica
                                                                                          Species
```

# ggplot() 함수: geom\_density

```
0.6-
ggplot(diamonds, aes(depth, fill = cut, colour = cut)) +
  geom_density(alpha = 0.1) +
  xlim(55, 70)
                                                                                           cut
                                                            0.4-
                                                                                              Fair
                                                           density
                                                                                              Good
                                                                                              Very Good
                                                                                              Premium
                                                                                              Ideal
                                                            0.2-
                                                                               65
                                                                          depth
```

## OOO ggplot() 함수: geom\_density

```
000
```

```
ggplot(diamonds, aes(carat, fill = cut)) +
  geom_density(position = "stack")
```

