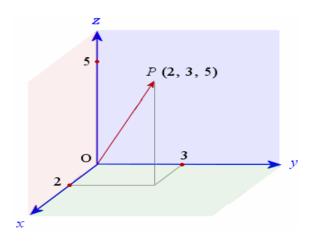
소프트웨어시스템 실습

6강:다차원 데이터 구성 및 OLAP



000

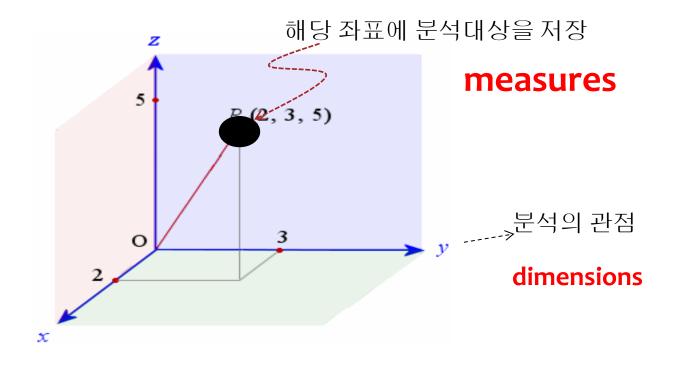
- ▶ Decision Making을 위해 특별히 설계된 'subject' 중심적인 데이터 저장소로서 다양한 'view'에서 관찰 분석이 가능
 - ▶ subject (measure) -> 'fact' 테이블
 - ▶ view -> 'dimension' 테이블



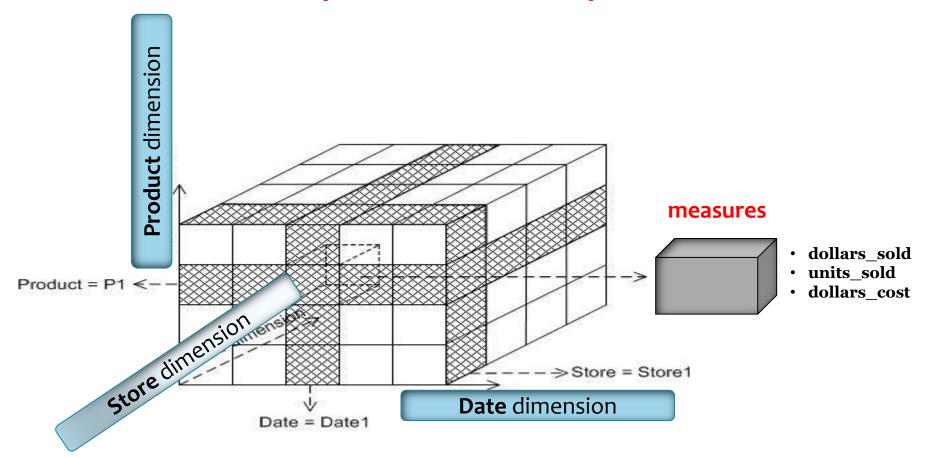


분석을 위한 DB의 구성?

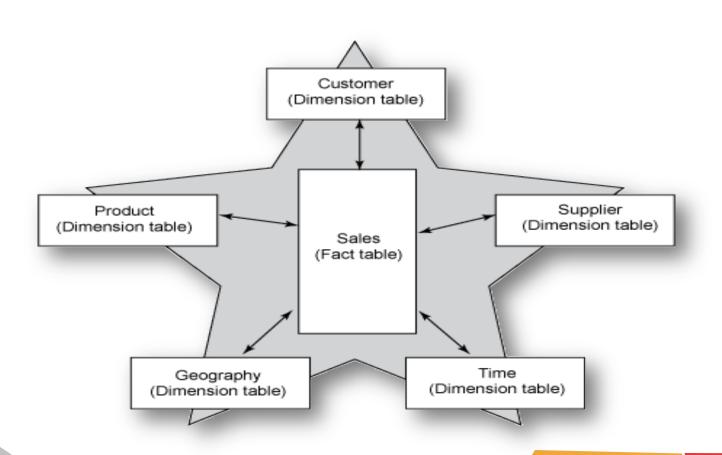


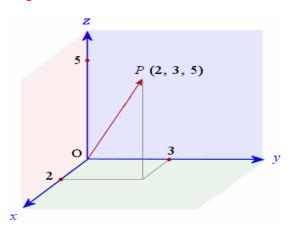


▶ Multi-dimensional DB (n차원 배열형태) 로 구축



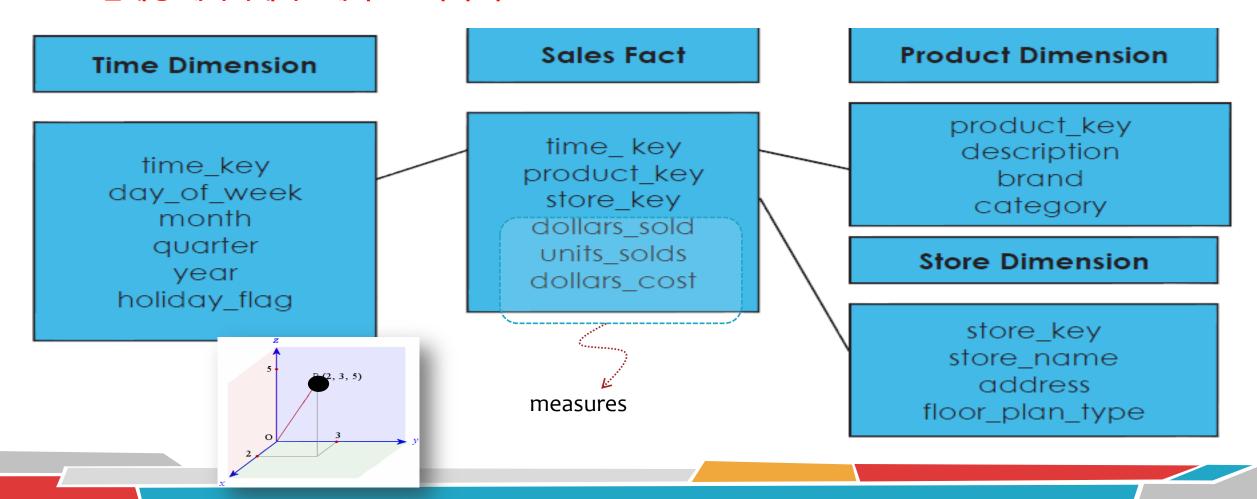
▶ 관계형 데이터베이스에서 MDB(Data Warehouse)의 구축





OOO Multi-Dimensional DB 스키마 OOO

▶ 관계형 데이터베이스에서 DW의 구축: Star schema model



000

Multi-Dimensional DB 구축



▶ Relational DB로 구축

'Time' Dimension 테이블

-7	time_key	day_of_week	month	quarter	year	holiday_flag

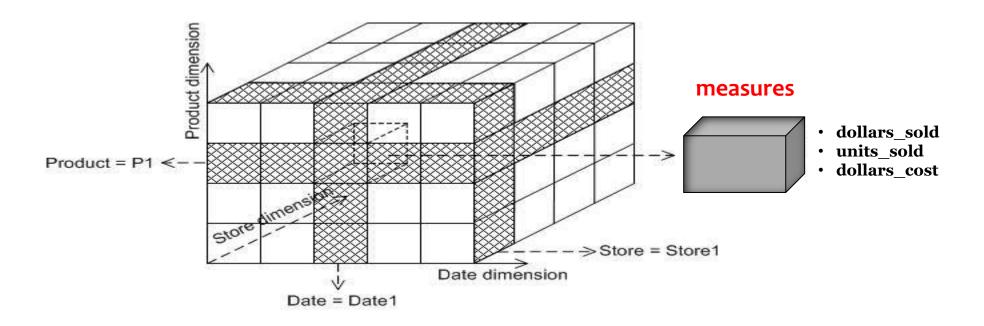
'Product' Dimension 테이블 'Store' Dimension 테이블

measures

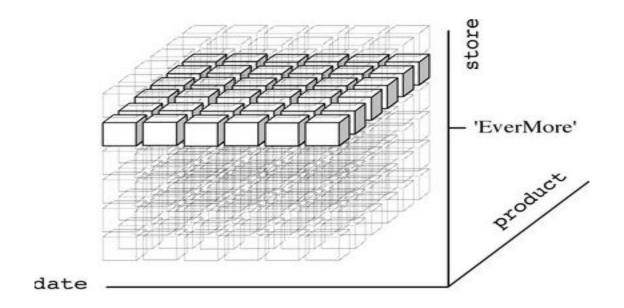
time_key (FK)	product_key (FK)	store_key (FK)	dollars_sold	units_sold	dollars_cost

O Multi-Dimensional DB 구축

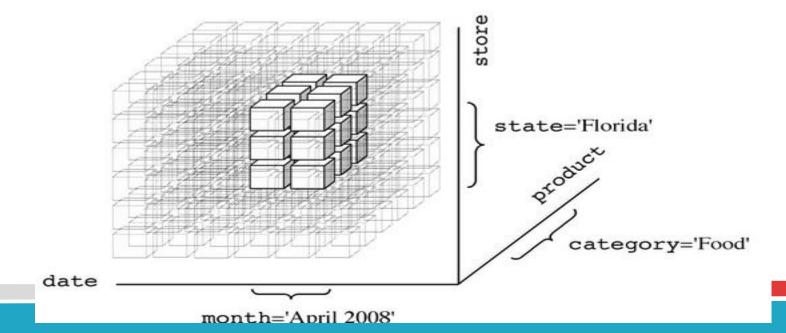
▶ Multi-dimensional DB로 구축



- ▶ 연산: Slicing
 - ▶ 특정 차원을 고정시켜놓고 다른 차원들의 데이터를 관찰
 - **)** 예:
 - ▶ 'EverMore' 지점을 고정하여, data, product 차원에서 판매 현황 관찰



- ▶ 연산: Dicing
 - ▶ 각 차원 마다 범위를 설정하여 보다 제한된 cube를 생성
 - **)** 예:
 - ▶ Time 차원 범위: 208년 4월
 - ▶ Product 차원 범위: Food 카테고리
 - ▶ Store 차원 범위: Florida

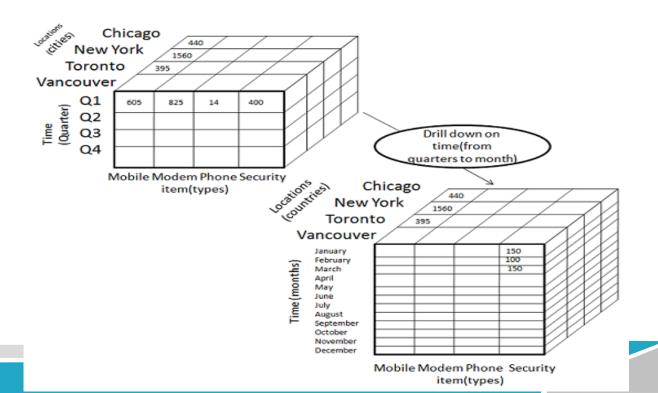


- ▶ 연산: Drill-down ("Show me more detail")
 - 상위 수준의 요약정보로부터 시작하여 단계적으로 관련된 구체 데이터를 추적하는 과정
 - **예**:
 - ▶ 2014년 분기별 판매량 정보

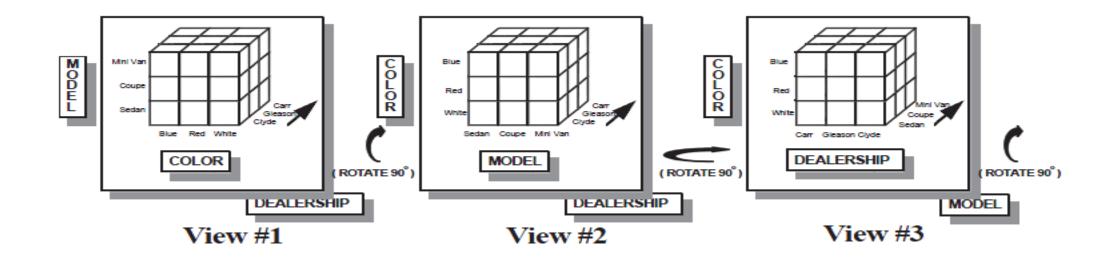


▶ 2014년 월별 판매량 정보

- ▶ 연산: Roll-up
 - ▶ drill-down의 반대 연산

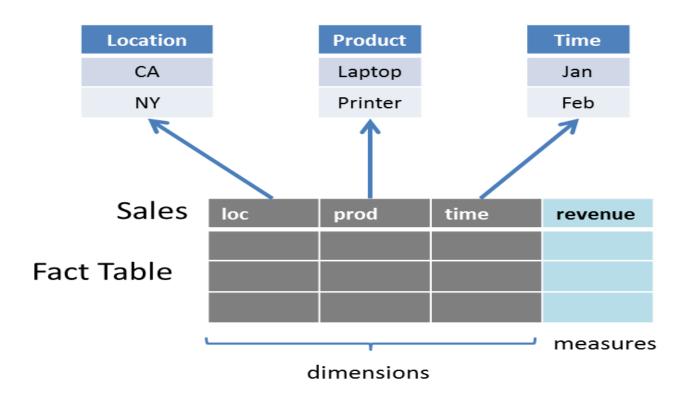


- ▶ 연산: Pivoting (or Rotating)
 - ▶ n개 차원의 방향을 전환
 - ▶ 새로운 차원의 삽입하면서 수행할 수도 있음



OOO Multi-Dimensional DB 스키마 OOO

Dimension Tables



OOO Multi-Dimensional DB 구축: R의 활용 OO

▶ Dimension 테이블의 구축

- ▶ **product** 차원 테이블: prod_table
- ▶ **time** 차원 테이블: month_table
- ▶ **location** 차원 테이블: state_table

OOO Multi-Dimensional DB 구축: R의 활용 OO

▶ Fact 테이블의 구축: random하게 measure 데이터 생성

```
gen_sales <- function(rec_num) {</pre>
 # Generate 'fact' data randomly
  loc <- sample(state table$key, rec num, replace=T, prob=c(2,2,1,1,1))</pre>
   loc <- sample(state_table$key, rec_num, replace=T, prob=c(2,2,1,1,1))</pre>
                     샘플링 대상
                                                                      샘플링 확률
  unit <- sample(c(1,2), rec_num, replace=T, prob=c(10, 3)) # 판매 개수
  amount <- unit * prod_table[prod,]$price # 판매금액 = 개수 * 단가
  sales <- data.frame(month=time month, year=time year, loc=loc, prod=prod,
                   unit=unit, amount=amount)
  sales <- sales[order(sales$year, sales$month),] # 시간에 따라 fact data의 sorting
  row.names(sales) <- NULL
  return(sales)
```

○○○ vector 또는 data.frame의 정렬 ○○○

sales <- sales[order(sales\$year, sales\$month),] 1차 정렬 2차 정렬

x <- c(10, 50, 40, 30, 5) order(x) # <u>5 1 4 3 2</u> 를 출력

5번째 값 < 1번째 값 < 4번째 값 < 3번째 값 < 2번째 값

x <- x[c(5,1,4,3,2)] # => x <- x[order(x)]

Multi-Dimensional DB 구축: R의 활용으 C

▶ 'Sales' Fact 테이블의 생성

```
sales fact <- gen sales(500)</pre>
head(sales fact)
                              state table
month table
                                        name country
                                                                   key price
                                                  USA
```

USA

USA

Canada

Canada

225

570

1120

Printer

Tablet

CA California

WA Washington

ON

new York

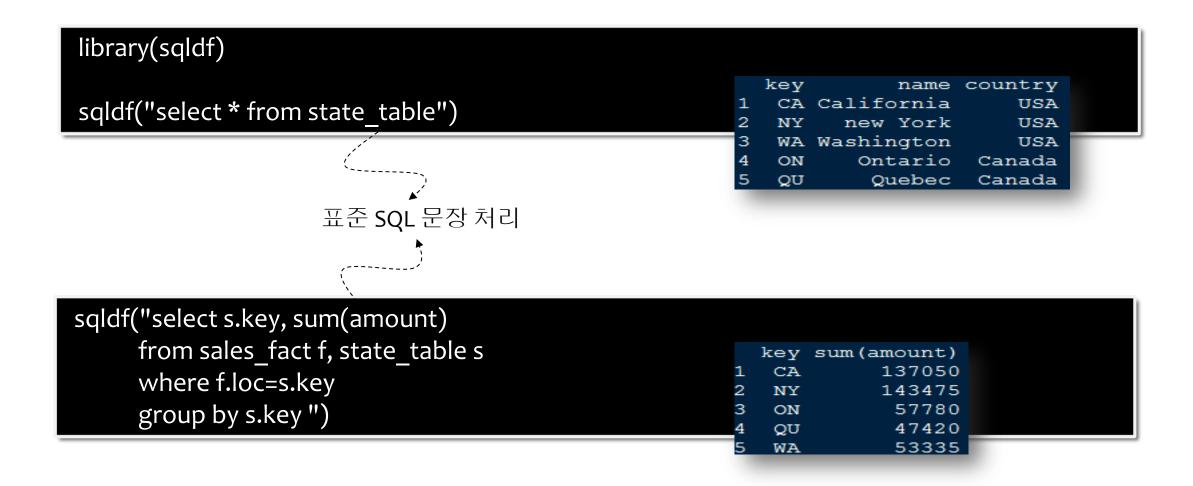
Ontario

Quebec

```
key desc quarter
       Jan
      Feb
      Mar
                   Q2
Q2
Q3
Q3
Q4
Q4
Q4
      Apr
      May
      Jun
      Ju1
      Aug
      Sep
      Oct
      Nov
       Dec
```

```
head(sales ƙact)
                   prod unit amount
month year
      2012
             ON
                 Laptop
                                  225
               Printer
      2012
                                 1140
                                 1120
      2012
             OH
                 Tablet
      2012
                 Tablet
                                 1120
      2012
             QU
                 Laptop
                                  225
      2012
             CA
                 Tablet
                                 1120
```

OOO Multi-Dimensional DB 구축: R의 활용OO

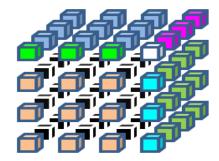


○○ Multi-Dimensional DB 구축: R의 활용 ○○

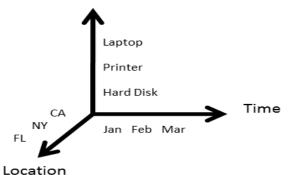
Sales Fact Table

state	product	year	month	unit	amount

Hypercube



Product





3D Cuboid

Revenue of (Laptop, NY, Feb)

2D Cuboids

Revenue sum of (Laptop, Feb) over (locations)

Revenue sum of (NY, Feb) over (Products)

Revenue sum of (Laptop, NY) over (Time)

1D Cuboids

Revenue sum of (Feb) over (products, locations)

Revenue sum of (CA) over (products, time)

Revenue sum of (Laptop) over (time, locations)

OD Cuboid

Revenue sum over (products, time, locations)

○○ Multi-Dimensional DB 구축: R의 활용 ○○

▶ 다차원 Multi-dimensinal DB(cube)의 생성

```
revenue_cube <- tapply(sales_fact$amount,
sales_fact[ , c("prod", "month", "year", "loc")],
FUN=function(x){return(sum(x))})
```

```
month
prod 1 2 3 4 5 6 7 8 9 10 11 12
Laptop 225 675 1125 NA 450 450 900 675 225 900 NA 675
Printer NA 1140 570 570 NA NA 1710 NA NA 1140 1710 570
Tablet 4480 3360 7840 7840 4480 6720 4480 2240 7840 6720 4480 4480

, , year = 2013, loc = CA

month
prod 1 2 3 4 5 6 7 8 9 10 11 12
Laptop 450 675 675 900 450 450 675 NA 450 675 900 NA
Printer 1710 NA NA 570 570 570 1140 NA NA NA 2280 570
Tablet 4480 4480 5600 3360 4480 2240 4480 6720 2240 6720 1120 2240

, , year = 2012, loc = NV

month
prod 1 2 3 4 5 6 7 8 9 10 11 12
Laptop 225 675 NA 450 225 900 225 675 900 225 225 NA
Printer 1710 570 NA 1710 570 2850 1140 1140 NA NA NA 1140
Tablet 1120 3360 2240 5600 NA 3360 2240 1120 2240 6720 8960 6720
```

> O O tapply 연습

2240

1120

1120

1120

1120

2240

1120

1120

1140

570

225

prod

Laptop

Tablet

NA 2240 NA 1120 3360

225

```
sales fact[1:20,]
                       prod unit amount
   month year loc
        8 2012
                     Tablet
                                 2
                 ON
        7 2012
                     Tablet
                 ON
3
        2 2012
                     Tablet
                 NY
4
5
6
7
        3 2013
                     Tablet
                                 1
                 QU
        6 2013
                 WA
                     Tablet
                                 1
        3 2012
                     Tablet
                                 2
                 CA
        9 2012
                                 1
                     Tablet
                 CA
                                 1
        6 2012
                 WA
                     Laptop
        7 2013
                     Tablet
                                 1
                 NY
10
        1 2013
                 OU Printer
                                 2
11
        5 2012
                 ON Printer
                                 1
12
        4 2013
                 QU
                     Laptop
13
       11 2012
                     Tablet
                 QU
14
        2 2013
                 WA
                     Tablet
15
                 QU Printer
        6 2012
16
        1 2012
                 NY
                     Tablet
17
        6 2012
                 NY
                     Laptop
                                 prod
18
        5 2012
                 NY Printer
                                   Laptop
19
       10 2013
                                    Printer
                 NY
                     Tablet
20
        9 2013
                 NY Printer
                                   Tablet
```

```
vector
                                      길이의 index (factor)
             tapply(test$amount, test[, c("prod")],
            Laptop Printer
                              Tablet
               900
                       3990
                               16800
                      SQL의 "group by" 연산과 유사
             tapply(test$amount, test[, c("prod", "loc")], sum)
                    loc
          prod
                       CA
                                            WA
                            NY
                                  ON
                                       QU
                                      225
                                           225
                           450
             Laptop
                                  NA
                       NA
             Printer
                       NA 1710
                                570 1710
                                            NA
             Tablet 3360 4480 3360 2240 3360
tapply(test$amount, test[, c("prod", "loc",
 year = 2012
       loc
           CA
                NY
                      ON
                           OU
                                WA
           NA
               450
                      NA
                           NA
                               225
           NA
               570
                     570
                          570
                                NA
        3360 2240 3360 1120
                                NA
, year = 2013
       loc
        CA
              NY ON
                       OU
                            WA
        NA
              NA NA
                      225
                             NA
Printer NA 1140 NA 1140
                             NA
```

첫 인자 vector와 동일한

OOO Multi-Dimensional DB 구축: R의 활용 OO

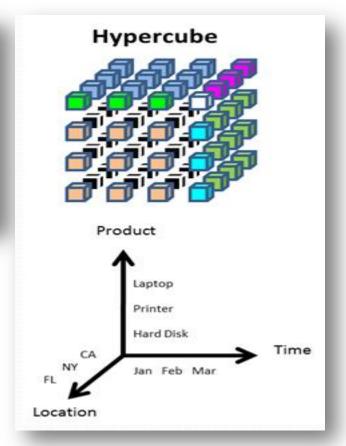
dimnames(revenue_cube)

```
> dimnames(revenue_cube)
$prod
[1] "Laptop" "Printer" "Tablet"

$month
  [1] "1" "2" "3" "4" "5" "6" "7" "8" "9" "10" "11" "12"

$year
[1] "2012" "2013"

$loc
[1] "CA" "NY" "ON" "QU" "WA"
```



- OLAP operations
 - Slice
 - Dice
 - Rollup
 - Drilldown
 - Pivot

Slicing

- # cube data in Jan, 2012
- revenue_cube[, "1", "2012",]

```
cube 차원 순서: "prod", "month", "year", "loc "
```

- # cube data in Jan, 2012
- revenue_cube["Tablet", "1", "2012",]

```
> revenue_cube[, "1", "2012",]
loc
prod CA NY ON QU WA
Laptop 225 225 225 NA
Printer NA 1710 NA NA NA
Tablet 4480 1120 1120 NA 1120
```

```
> revenue_cube["Tablet", "1", "2012",]
CA NY ON QU WA
4480 1120 1120 NA 1120
```



scube <- revenue_cube[c("Tablet","Laptop"),</p>



```
c("1","2","3"), ,
c("CA","NY")] # dicing
```

```
cube 차원 순서 : "prod", "month", "year", "loc "
```

▶ scube[, "1", , "CA"] # 작은 size의 cube에서 질의

```
> scube[,"1",,"CA"]
year
prod 2012 2013
Tablet 4480 4480
Laptop 225 450
```

cube 차원 순서 : "prod", "month", "year", "loc "

- ▶ 관찰하고 싶지 않은 차원을 없애기 위해 집계함수(aggregation function) sum 을 이용
- 예: year, prod, loc 차원에 대해 데이터 관찰 -> loc 차원 없애고, year, prod 차원에 대해 데이터 관찰

```
apply(revenue_cube, c("year", "prod"),
FUN=function(x) {return(sum(x, na.rm=TRUE))})

(n차원) array

prod
year Laptop Printer Tablet
2012 23175 27360 192640
2013 20025 26790 170240
```

FUN함수를 적용하게 되는 기준 컬럼

Drill-down

- 차원의 추가 또는 차원 하향 레벨링을 통해 세밀하게 데이타 관찰
- ▶ 예: 각 product에 대한 매년 판매량 관찰 -> 매달 판매량 관찰

```
apply(revenue_cube, c("year", "month", "prod"),
FUN=function(x) {return(sum(x, na.rm=TRUE))})
```

```
month
year 1 2 3 4 5 6 7 8 9 10 11 12
2012 900 4050 3150 900 1800 2475 2700 2025 1575 1575 450 1575
2013 1350 900 2250 1125 2250 2025 2475 1575 1800 1575 2025 675

, , prod = Printer

month
year 1 2 3 4 5 6 7 8 9 10 11 12
2012 1710 3990 1140 2850 570 4560 3990 1140 1140 2280 2280 1710
2013 2280 1710 3420 1140 2280 1710 2850 2280 1140 1710 5700 570

, , prod = Tablet

month
year 1 2 3 4 5 6 7 8 9 10 11 12
2013 280 1710 3420 1140 2280 1710 2850 2280 1140 1710 5700 570

, , prod = Tablet

month
year 1 2 3 4 5 6 7 8 9 10 11 12
2012 7840 17920 15680 16800 6720 11200 17920 11200 19040 23520 26880 17920
2013 14560 20160 13440 14560 12320 6720 19040 17920 6720 23520 14560 6720
```

Pivoting

예: year vs. month (또는 month vs. year) 차원에 대한 판매량 관찰

```
apply(revenue_cube, c("year", "month"),
FUN=function(x) {return(sum(x, na.rm=TRUE))})
```

```
month
year 1 2 3 4 5 6 7 8 9 10 11 12
2012 10450 25960 19970 20550 9090 18235 24610 14365 21755 27375 29610 21205
2013 18190 22770 19110 16825 16850 10455 24365 21775 9660 26805 22285 7965
```

예: product vs. location (또는 location vs. product) 차원에 대한 판매량 관찰

```
apply(revenue_cube, c("prod", "loc"),
FUN=function(x) {return(sum(x, na.rm=TRUE))})
```

```
loc
prod CA NY ON QU WA
Laptop 12600 11025 6300 8550 4725
Printer 14820 18810 5130 8550 6840
Tablet 113120 97440 51520 43680 57120
```